面向清史研究的自主考据智能体

——基于 Search-o1 启发式推理与三位一体史料库的构建

林江锋 周逸静 陈嘉铭

背景介绍



现状：清史研究已进入大数据时代，《清实录》、数百万件奏折及各类辞典已完成初步数字化。

然而，尽管现有数字化手段已显著提升史料获取效率，但在深层语义理解、跨史料关联和高质量证据筛选方面，仍存在一定改进空间。



背景介绍

为什么普通 RAG 不行？

- **语义断层：**现代汉语提问与半文言史料无法直接匹配。
- **孤证不立：**历史研究需要多库互证，而现有RAG只能检索单一片段。
- **长周期盲点：**传统RAG无法关联跨越数十年的因果事件（如“冤案-长期监禁-平反”）。

面向清史研究的智能体构建

- **建设目标：**构建兼具术语解释、史料检索、跨文类关联与证据化回答能力的研究型智能体系统。完成历史实体规范化、时间推理、证据链组织。
- **具体路径：**通过Search-o1的启发式架构，将“被动检索”提升为“主动追问”，实现从孤立片段到完整证据链的重构。

多源历史数据：辞典、奏折、编年史书

三位一体史料库介绍

- 使用 “关系数据库（SQL）+ 图数据库（Neo4j）”，用于建立“人-地-职”的关联。
- 注明使用 “向量数据库（ChromaDB/Milvus）”存储向量，以及 “全文检索引擎（ES/BM25）”存储原文。
- 史料经过了 “段落级切分” 和 “元数据标注”（如时间戳、地理坐标、唯一人物 ID）。



概念层（词典）：
职官、制度、术语。作用：语义解码、查询改写。



时空层（实录）：
编年史。作用：锁定官方标准时间轴、最终定性。



证据层（奏折）：
原始档案。作用：挖掘微观细节、博弈过程、非正式史实。

多源历史数据：概念层（词典库）

检索方案： 知识图谱（关系跳转）+BM25（字面精准）

基于知识图谱的符号检索

- 意象归一化

  利用 alias_map 将查询词映射为标准意象
- 解决“同义异名”问题
- 将用户的现代词汇（如：台湾省长）改写为历史标准词（如：福建台湾巡抚）

意象感知 BM25稀疏检索

- 最大正向匹配（FMM） 进行分词
- 优先级：

  意象词（alias 中最长优先）

> 古文常见词（common_vocab）

> 单字

确保专有名词不被错误切分，如将“燕山”切分成“燕”“山”

语义向量稠密检索

- 高维语义映射 (Embedding)

  采用 BGE-Small 模型计算 Query-Doc 余弦相似度
- 多视图文档扩展

  索引单元包含：原文 + 白话译文 + 深度赏析
- 跨语体对齐

  弥合“现代口语查询”与“文言文文本”的语义鸿沟

多源历史数据：证据层（奏折档案）

检索方案：混合检索（Hybrid Search）+ 关系加权重排

01

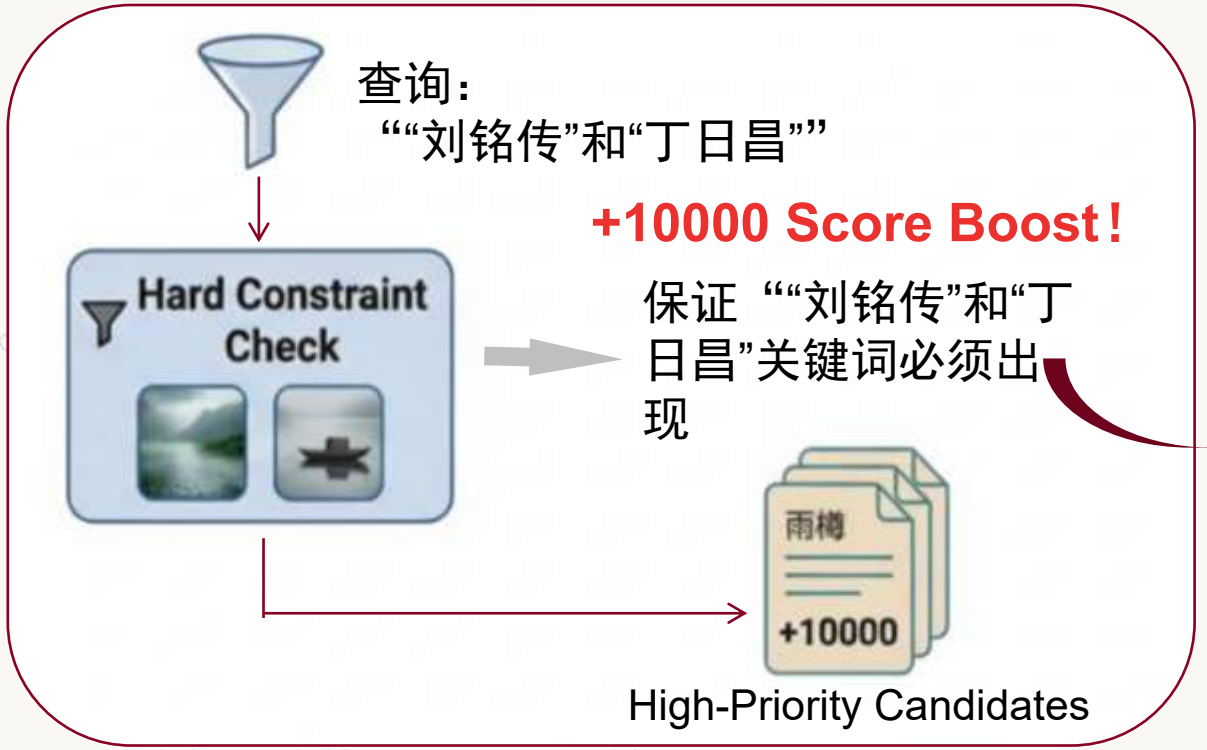
Tier 1 (硬约束):

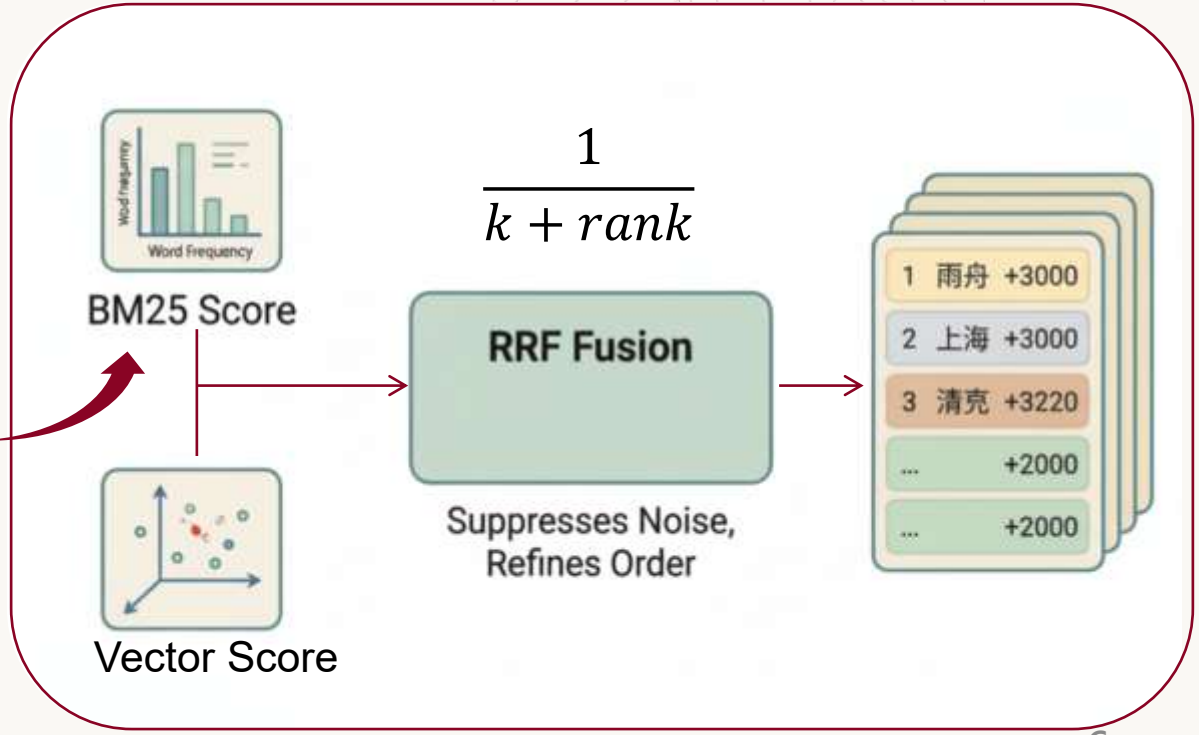
关键事物覆盖度优先

02

Tier 2 (软得分):

同级内使用 RRF（倒数排名融合）结合向量分与 BM25 分。





多源历史数据：时空层（编年实录）

检索方案：元数据过滤（Metadata Filter）+ 线性扫描。

帝号	年号纪年	干支纪年	农历月	是否闰月	农历日	干支纪日	原始公历日	标准公历日	事件正文	注释	来源
康熙	康熙元年	壬寅	正月	FALSE	初一日	乙亥	1662年2月1	1662-02-18	元旦。因顺治帝之丧，		清史编年02.康熙朝
康熙	康熙元年	壬寅	正月	FALSE	十九日	癸巳	3月8日	1662-03-08	准刑部题，凡官吏审		清史编年02.康熙朝
康熙	康熙元年	壬寅	正月	FALSE	二十五日	己亥	3月14日	1662-03-14	江宁巡抚朱	① 丁艰，	清史编年02.康熙朝
康熙	康熙元年	壬寅	二月	FALSE	初七日	辛亥	3月26日	1662-03-26	甄别督抚：② 休致，		清史编年02.康熙朝
康熙	康熙元年	壬寅	二月	FALSE	初七日	辛亥	3月26日	1662-03-26	本日，命内大臣、理		清史编年02.康熙朝
康熙	康熙元年	壬寅	二月	FALSE	十二日	丙辰	3月31日	1662-03-31	因翰林院已裁并内三		清史编年02.康熙朝
康熙	康熙元年	壬寅	二月	FALSE	二十六日	庚午	4月14日	1662-04-14	得平西大将军平西王		清史编年02.康熙朝
康熙	康熙元年	壬寅	二月	FALSE	二十六日	庚午	4月14日	1662-04-14	是月，郑	① 徐鼒：	清史编年02.康熙朝
康熙	康熙元年	壬寅	三月	FALSE	初二日	乙亥	4月19日	1662-04-19	从兵部议，以后推升		清史编年02.康熙朝
康熙	康熙元年	壬寅	三月	FALSE	初八日	辛巳	4月25日	1662-04-25	旧例武职官叙功至左		清史编年02.康熙朝
康熙	康熙元年	壬寅	三月	FALSE	十二日	乙酉	4月29日	1662-04-29	清廷以朱由榔就擒，		清史编年02.康熙朝
康熙	康熙元年	壬寅	三月	FALSE	二十六日	己亥	5月13日	1662-05-13	遣郎中岳诺惠等六员		清史编年02.康熙朝
康熙	康熙元年	壬寅	四月	FALSE	初一日	甲辰	5月18日	1662-05-18	准凤阳巡抚林起龙疏		清史编年02.康熙朝
康熙	康熙元年	壬寅	四月	FALSE	初八日	辛亥	5月25日	1662-05-25	从吏部议，总督加兵		清史编年02.康熙朝
康熙	康熙元年	壬寅	四月	FALSE	十四日	丁巳	5月31日	1662-05-31	四川总督李国英疏报，		清史编年02.康熙朝
康熙	康熙元年	壬寅	五月	FALSE	初八日	庚辰	6月23日	1662-06-23	郑成功（1	① 据《小	清史编年02.康熙朝

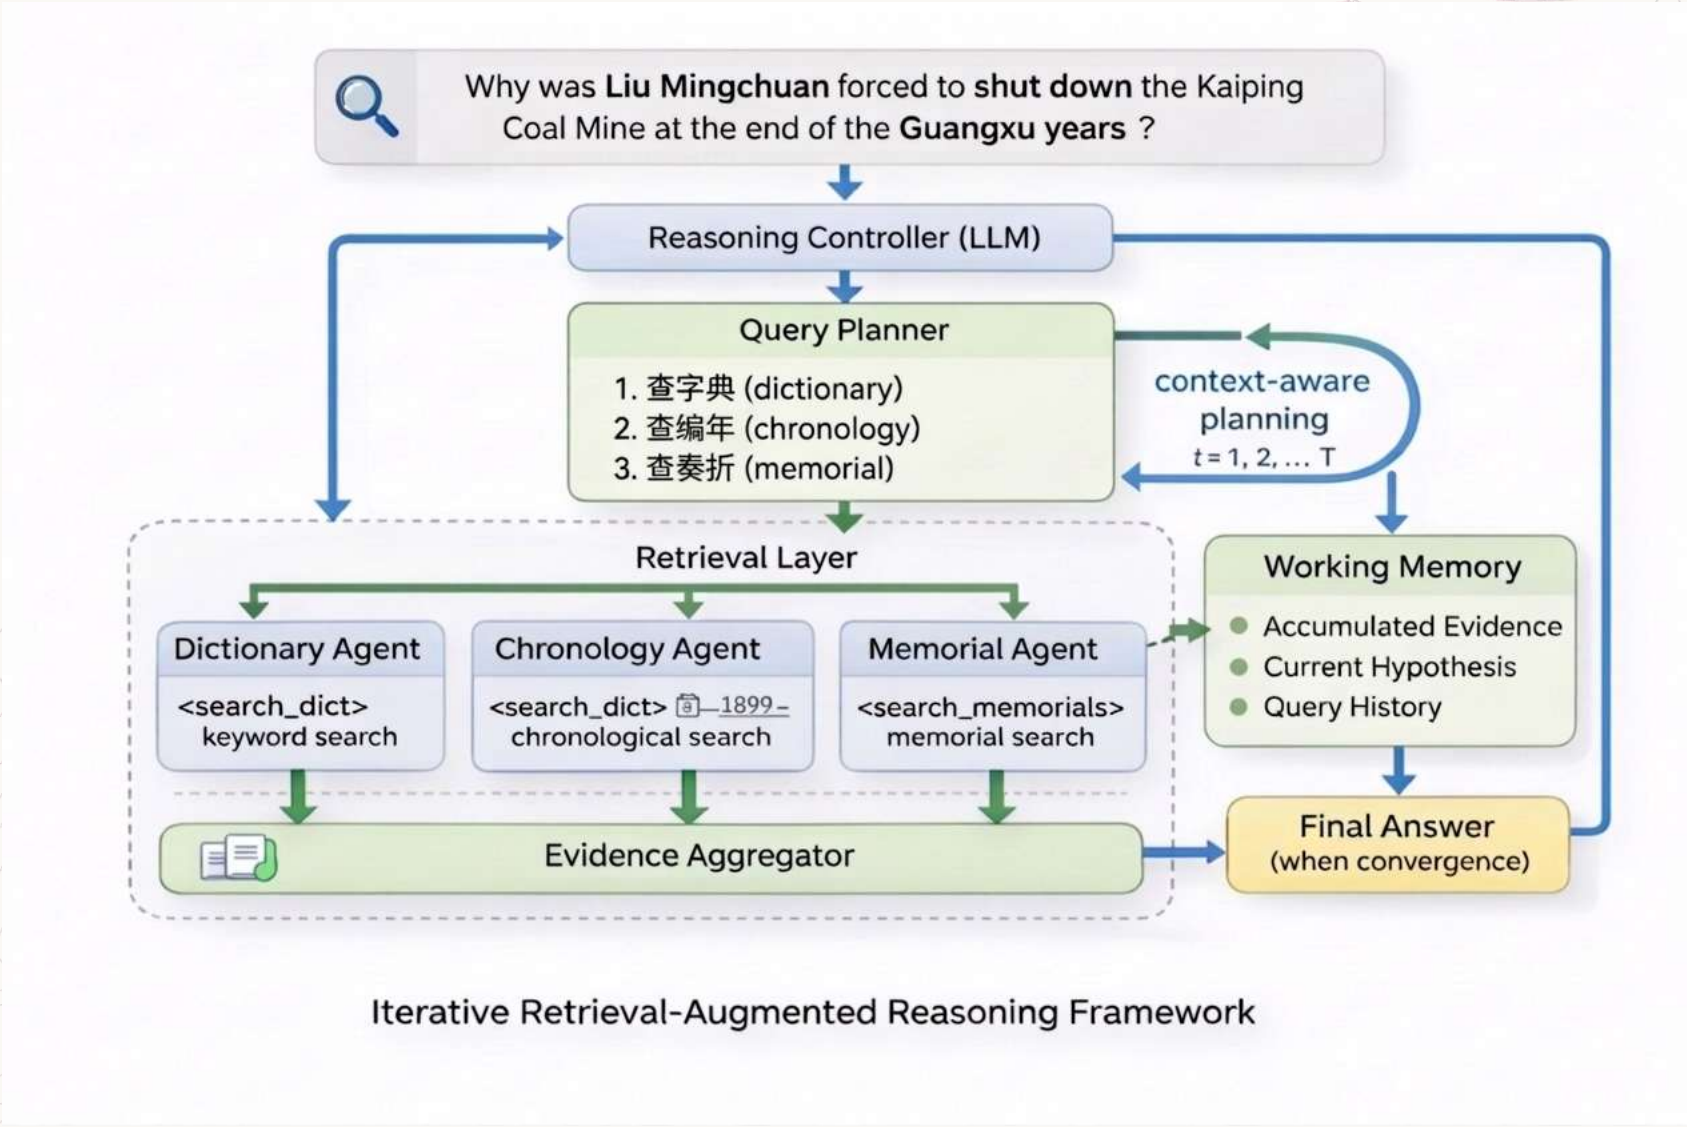
- **结构化数据：**标注每一条记录都包含：朝代、年号、公历起止、时间粒度。
- 实录是按日排列的。检索时，系统会先通过奏折确定一个“时间点”，然后在实录中开启一个“时间窗口”（例如前后12个月）进行定向检索，确保事件的结局能被精准捕捉。
- 系统支持“相对时间窗口过滤”和“跨皇帝时期的连续区间检索”

技术路线与架构设计

维度	简单发放式智能体（Common Agent）	基于 Search-o1 的考据智能体（Ours）
检索逻辑	线性/一次性： 接到指令 → 搜三库 → 汇总。	循环/启发式： 边思考边搜，发现证据不足自动补链。
知识处理	信息搬运： 把搜到的原文丢给模型。	RiD（Reason-in-Docs）： 先理解史料大意，再带入逻辑分析。
考据能力	容易被骗： 如果奏折撒谎，AI 就跟着错。	矛盾检测： 自动比对“奏折说辞”与“实录定论”的冲突。
应对复杂题	回答肤浅： 只能回答“是什么”。	深度分析： 能回答“为什么”和“事件如何演变”。

- 引入 Search-o1 思想：改变“一次性检索”模式。
- 逻辑内核：AI 在思考过程中发现“知识缺口”→自主选择工具→迭代完善证据链。

系统总体架构图



Iterative Retrieval-Augmented Reasoning Framework

关键技术 1：Agentic Search 迭代循环

ReAct 框架：

Thought（思考需查什么）→Action（调用特定库）→Observation（分析史料）→Update Thought

- 推理主控模型在思考时，如果检测到模糊词（如“可能”、“或许”），会暂停生成，转而调取检索工具。
- 标签机制：

  <search_dict>：当识别到陌生职官（如“折奏处”）时自动触发。

  <search_memorials>：当发现事件细节缺失（如“具体赏赐数额”）时触发。

- 最大搜索深度（Max Search Limit）：防止 Agent 陷入无休止的搜索，保证回答的时效性。

关键技术 2：多智能体考据协同 (Multi-Agent)

01 推理主控（Query Parser Agent）

任务拆解与意图路由。

将宽泛的提问转化为针对性的检索计划（如：查人物仕历 + 查相关军备）。

02 资料检索员（Search Agent）

执行混合检索与元数据过滤。

在三库中进行语义及字面的双路召回，并根据时空范围对结果进行先验筛选。

03 史料精炼员（RiD Agent）

文言文转述/去噪。

把几千字的奏折精简成 200 字的核心史实，防止长文本干扰 AI 逻辑。

04 证据归并员（Evidence Organizer）

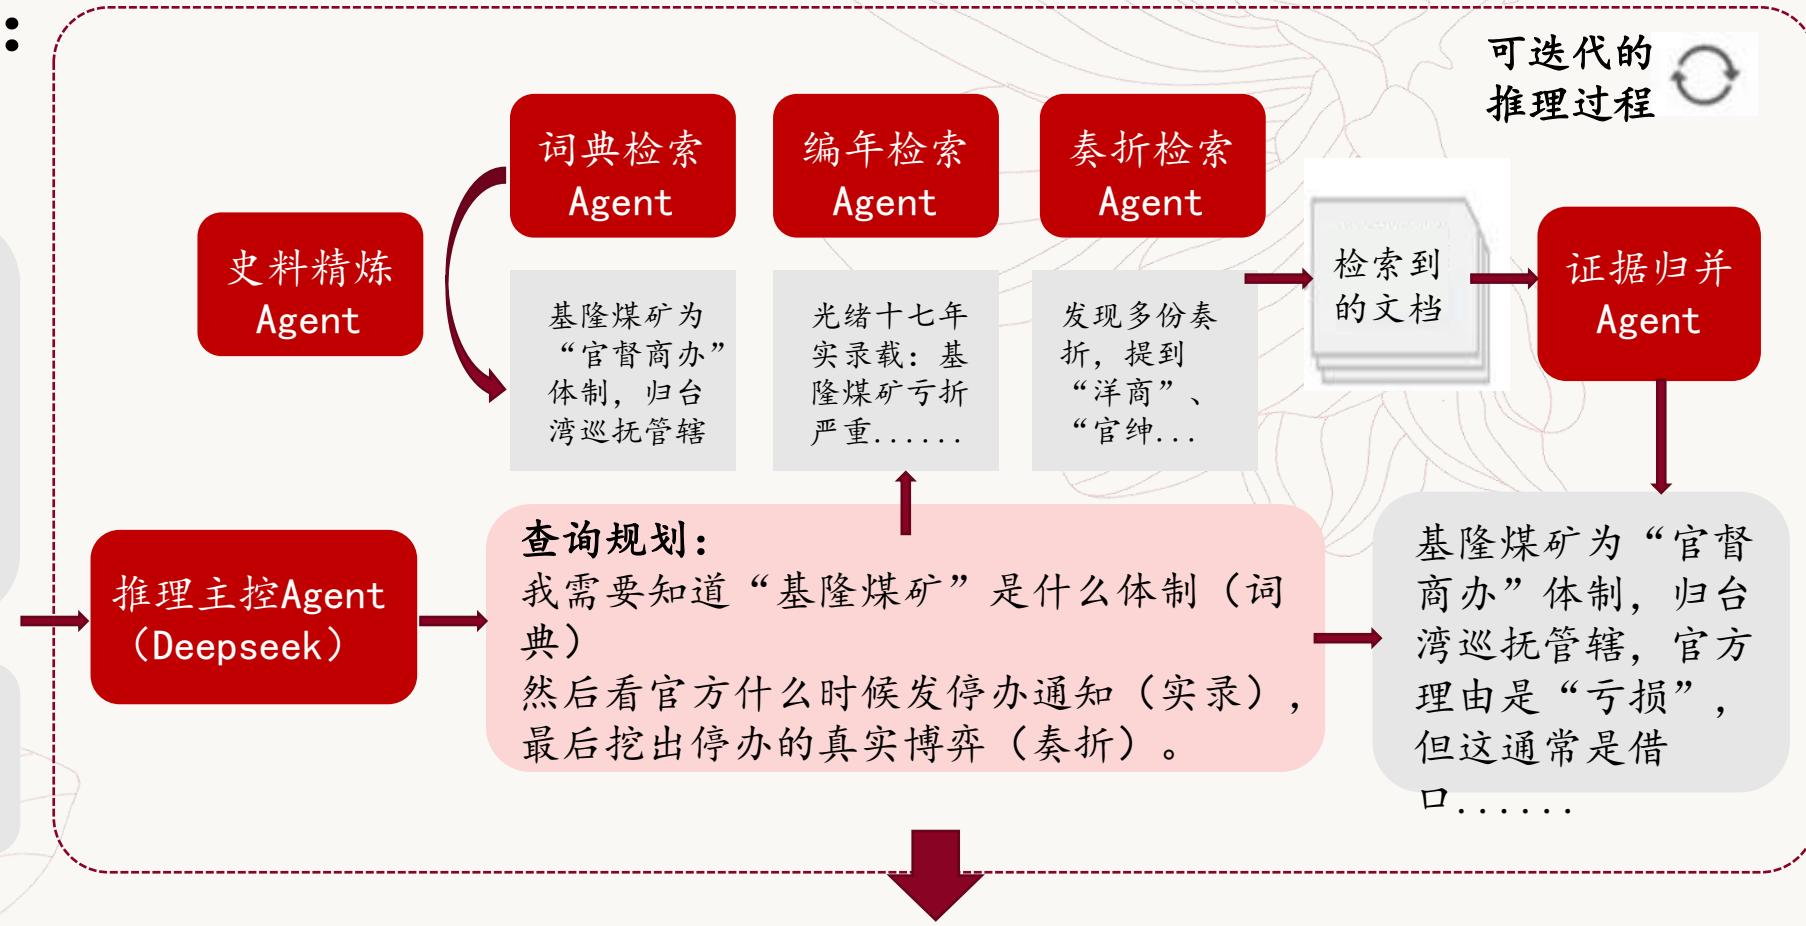
证据链拼图。

负责把词典的定义、实录的时间、奏折的细节整合为逻辑闭环。在实录与奏折产生明显矛盾时，触发“矛盾标记”以待人工研判。

复杂案例推演实例：

搜索指令：
“你是一个清史专家。在回答前，请先输出你的思考过程。如果你发现需要查询资料，请输出特定标签：
<search_dict>关键词</search_dict>
<search_memorials>关键词</search_memorials>
在获取资料前，不给出最终结论。”

原始问题：
光绪年间，刘铭传支持开办基隆煤矿，但为何最终被朝廷叫停？



阶段性成果：数据初步处理结束

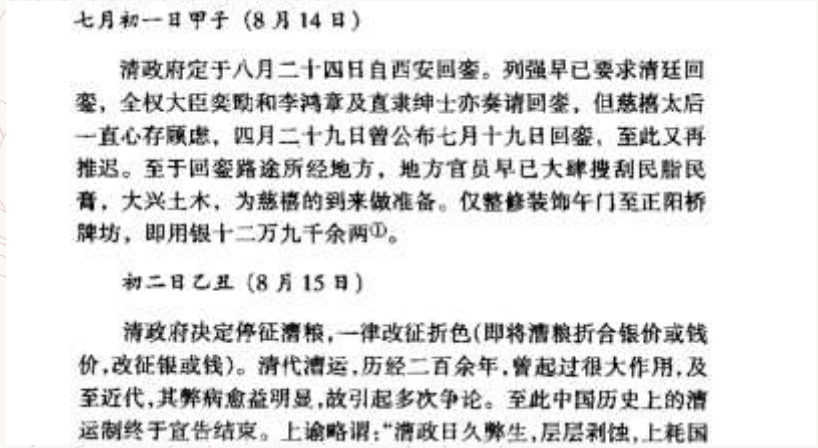
- 编年 & 词典

对《故宫辞典》和《清史编年》的PDF版本

进行ocr处理提取文本内容

进行数据结构化整理，提取日期、注释等内容

最终输出标准化CSV格式文件



七月初一日甲子（8月14日）

清政府定于八月二十四日自西安回銮。列强早已要求清廷回銮，全权大臣奕劻和李鸿章及直隶绅士亦奏请回銮，但慈禧太后一直心存顾虑，四月二十九日曾公布七月十九日回銮，至此又再推迟。至于回銮路途所经地方，地方官员早已大肆搜刮民脂民膏，大兴土木，为慈禧的到来做准备。仅整修装饰午门至正阳桥牌坊，即用银十二万九千余两①。

初二日乙丑（8月15日）

清政府决定停征漕粮，一律改征折色（即将漕粮折合银价或钱价，改征银或钱）。清代漕运，历经二百余年，曾起过很大作用，及至近代，其弊病愈益明显，故引起多次争论。至此中国历史上的漕运制终于宣告结束。上谕略谓："漕政日久弊生，层层剥蚀，上耗国

编年处理前

帝号	年号纪年	干支纪年	农历月	是否闰月	农历日	干支纪日	原始公历日期	标准公历日期
光绪	光绪元年	乙亥	正月	FALSE	初一日	己亥	2月6日	1875-02-06
光绪	光绪元年	乙亥	正月	FALSE	初十日	戊申	2月15日	1875-02-15
光绪	光绪元年	乙亥	正月	FALSE	十二日	庚戌	2月17日	1875-02-17
光绪	光绪元年	乙亥	正月	FALSE	十六日	甲寅	2月21日	1875-02-21
光绪	光绪元年	乙亥	正月	FALSE	十七日	乙卯	2月22日	1875-02-22
光绪	光绪元年	乙亥	正月	FALSE	二十日	戊午	2月25日	1875-02-25
光绪	光绪元年	乙亥	正月	FALSE	二十九日	丁卯	3月6日	1875-03-06
光绪	光绪元年	乙亥	二月	FALSE	初三日	辛未	3月10日	1875-03-10
光绪	光绪元年	乙亥	二月	FALSE	十二日	庚辰	3月19日	1875-03-19

编年处理后

阶段性成果：数据初步处理结束

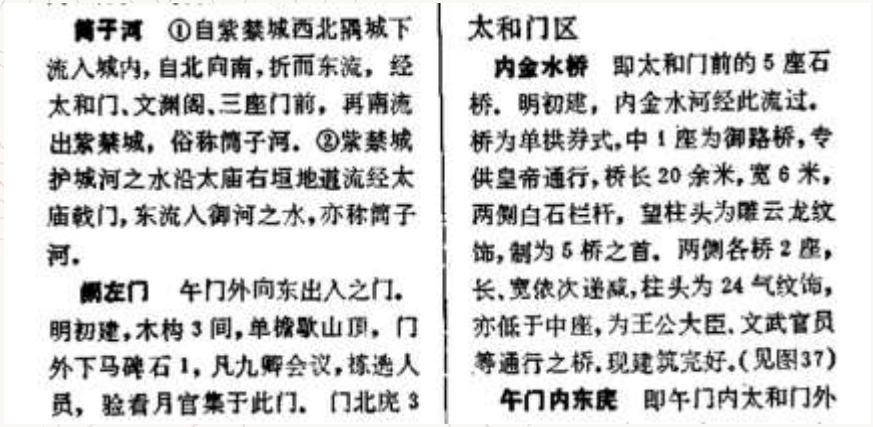
- 编年 & 词典

对《故宫辞典》和《清史编年》的PDF版本

进行ocr处理提取文本内容

进行数据结构化整理，提取日期、注释等内容

最终输出标准化CSV格式文件



筒子河 ①自紫禁城西北隅城下流入城内，自北向南，折而东流，经太和门、文渊阁、三座门前，再南流出紫禁城，俗称筒子河。②紫禁城护城河之水沿太庙右垣地道流经太庙戟门，东流入御河之水，亦称筒子河。

侧左门 午门外向东出入之门。明初建，木构3间，单檐歇山顶，门外下马碑石1，凡九卿会议，挑选人员，验看月官集于此门。门北庑3

太和门区

内金水桥 即太和门前的5座石桥。明初建，内金水河经此流过。桥为单拱券式，中1座为御路桥，专供皇帝通行，桥长20余米，宽6米，两侧白石栏杆，望柱头为瞎云龙纹饰，制为5桥之首。两侧各桥2座，长、宽依次递减，柱头为24气纹饰，亦低于中座，为王公大臣、文武官员等通行之桥。现建筑完好。(见图37)

午门内东庑 即午门内太和门外

词典处理前

条目	解释	来源	类型
明清宫殿建筑	明洪武元年（1368）八	故宫词典	明清宫殿建筑之部
大明门	明代北京皇城正南门。	故宫词典	明清宫殿建筑之部-外朝中路-午门之南
大清门	清代北京皇城正南第一	故宫词典	明清宫殿建筑之部-外朝中路-午门之南
天街	大清门外的小广场，百	故宫词典	明清宫殿建筑之部-外朝中路-午门之南
千步廊	大清门内东西向朝房。	故宫词典	明清宫殿建筑之部-外朝中路-午门之南
金水河	由乾(西北)位流入皇城	故宫词典	明清宫殿建筑之部-外朝中路-午门之南
外金水桥	即天安门前的5座石桥，	故宫词典	明清宫殿建筑之部-外朝中路-午门之南
天安门	清北京皇城的正门。建	故宫词典	明清宫殿建筑之部-外朝中路-午门之南
承天之门	明代皇城正门。始建于	故宫词典	明清宫殿建筑之部-外朝中路-午门之南
承天门	即明承天之门的简称。	故宫词典	明清宫殿建筑之部-外朝中路-午门之南

词典处理后

阶段性成果：数据初步处理结束

- 档案

爬取中央研究院历史语言研究所内阁大库档案数据

并整理为结构化数据



檔案处理前

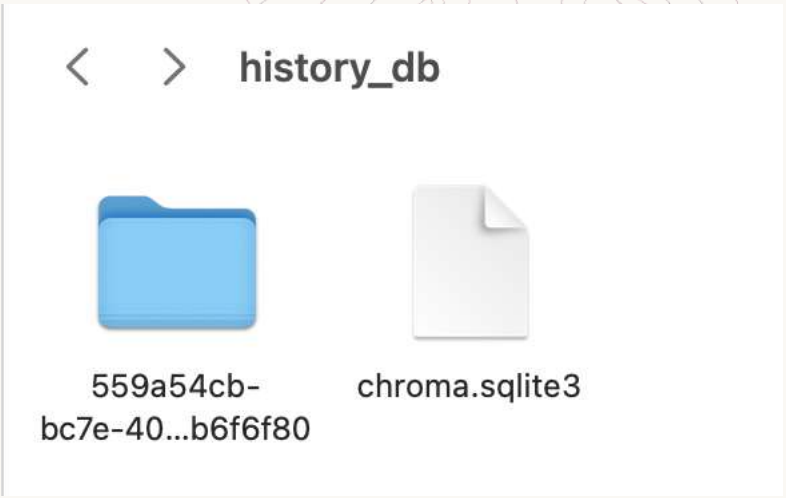


檔案处理后

阶段性成果：奏折数据向量化入库

- 模型：BGE-M3 模型
- 数据清洗成果：3598条光绪朝结构化数据入库

```
C:\vscode.c\Data_Science_Practice\检索\test\databas
  embedding_fn = MyBGEEmbeddingFunction()
正在处理数据...
开始存入数据库，共 1954 条数据...
100%|
数据库构建完成！
```



检索实验展示：

- 案例演示：输入“台湾防御”这一查询，系统能够成功召回与该主题高度相关的刘铭传与沈葆桢等人的奏折文献。
- 结论：初步证明了 BGE-M3 在半文言语境下的强大语义关联能力。

```
--- 测试检索 ---
结果 1:
内容：时间：光绪，日期：1895-03-15。事件内容：因吴大澂电奏内有“严饬将领只准前进，不准退扎”等语，谕称：吴大澂向来语多夸大，一似杀贼致果，自信甚深。乃自牛庄溃退，
吴大澂接奉此旨，著即统率所部移扎锦州，严密防守。
是日，日本联合舰队驶赴我台湾省属澎湖列岛，意在侵占。先是上年十一月间，日本首相伊藤博文向其大本营提出“进攻威海卫占领台湾方略”，认为直逼北京...
出处：⊕ 转引自丁名楠：《略谈日本发动甲午战争的背景、过程及其影响》，载戚其章主编：《甲午战争九十周年纪念文集》，16页，济南，山东人民出版社，1986。
------------------------------
结果 2:
内容：时间：光绪，日期：1895-05-16。事件内容：以台民誓拒割让，而日本派员已将到台，电谕驻法参赞庆常密询法外部可否“保护台湾”。又命李鸿章“仍妥筹办法”，“以期补救万一
出处：未知
------------------------------
结果 3:
内容：时间：光绪，日期：1884-10-03。事件内容：谕：台防万紧，曾国荃、穆图善等无论如何为难，须设法与台互通消息，妥筹接应。如台北不能登岸，其台南一带但有可通之路，
彭玉麟、张之洞等急筹援济，李鸿章如有可设法之处，亦著一体详筹。务使台湾兵械一切无缺乏之虑，俾得保卫岩疆，以慰廑念。。出处：未知...
出处：未知
```

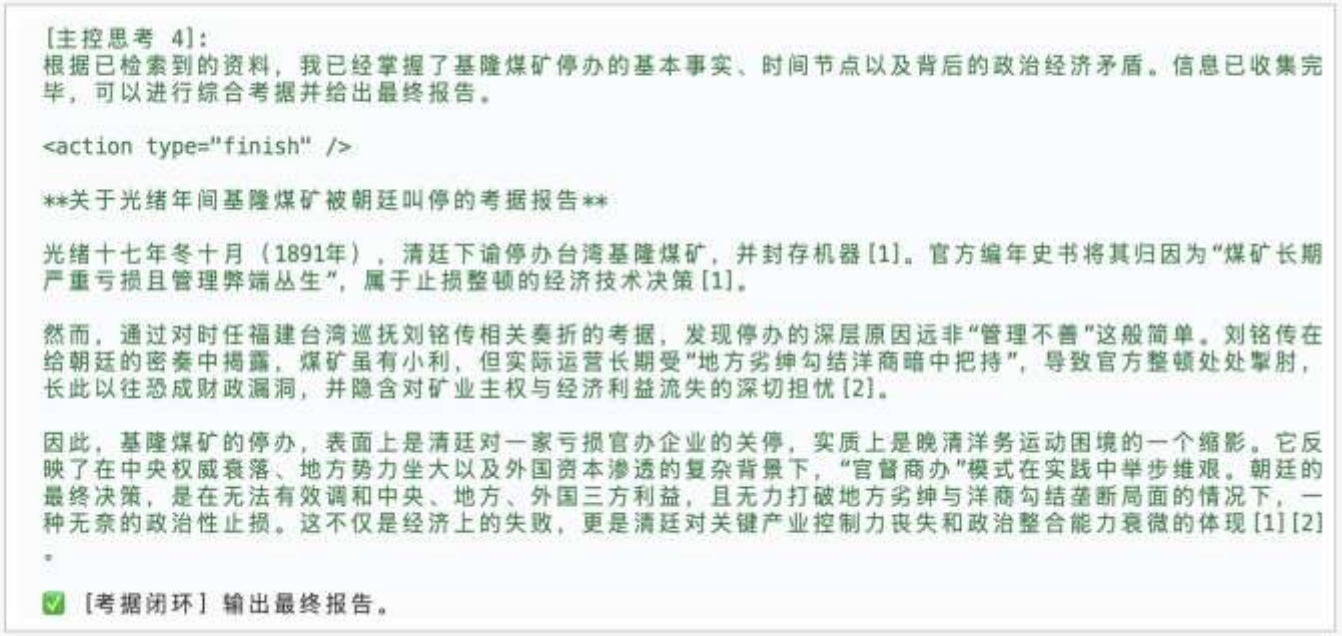
Agent实验展示：

当前实现：初步搭建 MasterReasoner、KnowledgeBase、RiD Agent 与 Conflict Analyzer 四个模块

循环框架：采用 XML Action + Working Memory，可按“查词典→查实录→查奏折”逐步补全证据链

案例结果：“基隆煤矿停办”案例已跑通，终端输出已出现互证矛盾告警，并能生成最终考据报告





工作计划和分工

分工安排：

- 林江锋负责数据工程：三库清洗、元数据标准化与索引优化；
- 周逸静负责链路开发：LangGraph 循环逻辑与 Agent 框架搭建；
- 陈嘉铭负责考据逻辑：Prompt 编写、评测集构建与学术复核。

进度规划：

- 我们计划在未来 8 周完成检索方案的实现和 Agent 的多步循环开发
- 并在最后 2 周进行全量数据的召回率与准确度评测

谢谢大家！

2026.4.7